

**UNIVERSIDAD PRIVADA ANTENOR ORREGO FACULTAD DE
INGENIERÍA
PROGRAMA DE ESTUDIO INGENIERÍA DE SISTEMAS E
INTELIGENCIA ARTIFICIAL**



**“Predicción de la Deserción Académica Universitaria mediante
Modelos de Aprendizaje Estadístico”**

INTEGRANTES

González Cipriano, Gerardo
Esquerre Martos, Charles Rances
Meza Alegria, Sebastian Alexandersson
Morán Cuyubamba, Jorge
Murillo Pérez, José Luis
Quevedo Alayo, Tatiana Antonella

ASIGNATURA

Aprendizaje Estadístico

DOCENTE

Sagastegui Chigne Teobaldo Hernan

FECHA

14/06/2026

NRC: 5562

TRUJILLO – PERÚ

ÍNDICE

1. Introducción.....	3
1.1. Título del Proyecto.....	3
1.2. Antecedentes.....	3
1.2.1. El Fenómeno de la Deserción en la Educación Superior.....	3
1.2.2. Contexto Nacional y Regional en el Perú (2024-2026).....	3
1.2.3. Evolución del Aprendizaje Estadístico en la Predicción Educativa.....	4
1.2.4. Justificación y Origen del Conjunto de Datos (Dataset).....	5
1.3. Problemas a Resolver.....	5
1.3.1. Realidad Problemática.....	5
1.3.2. Formulación del problema.....	6
1.4. Objetivos.....	6
1.4.1. Objetivo General.....	6
1.4.2. Objetivos Específicos.....	7
2. Requerimientos.....	7
2.1. Definición del Dominio.....	7
2.2. Determinación de Requisitos (Requerimientos).....	8
2.2.1. Requerimientos Técnicos.....	8
2.2.2. Requerimientos Funcionales.....	8
3. Planteamiento del Data-Set (por Aprendizaje Supervisado o Aprendizaje no-Supervisado).....	9
3.1. Medidas, Datos, Bases de Datos para la elaboración del Data-Set.....	9
3.2. Normalización y/o Filtrado de Datos.....	11
3.3. Planteamiento (para proyectos basados en el contexto de ML y DI) de:.....	12
3.3.1. Data-Set de entrenamiento (training).....	12
3.3.2. Data-Set de Pruebas (test).....	12
3.3.3. Data-Set de Validación por “Cross-Validation”.....	13
4. Aprendizaje:.....	13
4.1. Planteamiento del Modelo de Aprendizaje.....	13
4.2. Desarrollo e Implementación del Modelo.....	14
4.2.1. Fase de Entrenamiento y Ajuste Paramétrico.....	14
4.2.2. Fase de Evaluación con Datos No Vistos (Conjunto de Prueba 20%).....	15
5. Comprobación.....	16
5.1. Aplicación al Modelo: uso del Data-Set de Entrenamiento y de Prueba.....	16
5.2. Evidencias Computacionales del Reporte de Clasificación y Matriz de Confusión...17	
5.3. Desglose y Sustentación Funcional del Código Fuente.....	17
6. Evaluación.....	20
6.1. Métricas y Evaluación del Modelo.....	20
6.2. Evaluación de desempeño del Sistema de IA del Proyecto.....	22
7. Referencias.....	25

1. Introducción

1.1. Título del Proyecto

Predicción de la Deserción Académica Universitaria mediante Modelos de Aprendizaje Estadístico

1.2. Antecedentes

1.2.1. El Fenómeno de la Deserción en la Educación Superior

La deserción universitaria se ha consolidado como uno de los desafíos más críticos y persistentes para los sistemas de educación superior a nivel global. No se trata de un evento aislado, sino de un proceso acumulativo de pérdida de motivación y capacidad de permanencia influenciado por factores económicos, académicos, sociales y personales (Realinho et al., 2021; Flores Satalaya, 2025). Cuando un estudiante abandona sus estudios, se genera un impacto negativo triple: el individuo ve truncado su proyecto de vida profesional, la universidad reduce su tasa de egreso y sostenibilidad financiera, y la sociedad pierde el capital intelectual necesario para su desarrollo tecnológico y económico (Tramallino & Marize Zeni, 2024).

Históricamente, las instituciones han abordado este problema de manera reactiva, analizando las causas una vez que el abandono es definitivo. Sin embargo, en la era de la transformación digital, el enfoque ha migrado hacia la analítica predictiva. La capacidad de anticipar el comportamiento estudiantil se ha vuelto una prioridad para las facultades de ingeniería, donde las tasas de abandono suelen ser más elevadas debido al rigor académico de las ciencias exactas (García Pacheco & Crespo Asqui, 2025). En este escenario, el uso de técnicas de Aprendizaje Estadístico (*Statistical Learning*) marca un punto de inflexión, permitiendo pasar de una gestión de crisis a una prevención basada en datos (Flores Satalaya, 2025).

1.2.2. Contexto Nacional y Regional en el Perú (2024-2026)

En el Perú, la deserción académica ha mostrado variaciones significativas en el último bienio. Según reportes del Ministerio de Educación (MINEDU), aunque se han implementado políticas de becas, la interrupción de estudios superiores alcanzó picos

preocupantes tras las crisis económicas recientes, estabilizándose en cifras que rondan el 12% a 15%. En la región de La Libertad, la situación no es ajena a esta realidad; la volatilidad de la inflación y la presión sobre los presupuestos familiares han obligado a muchos jóvenes a priorizar el empleo sobre la formación académica.

Investigaciones recientes subrayan que en el contexto peruano existe una correlación directa entre la adaptabilidad académica y el abandono estudiantil. Los estudiantes de primer año enfrentan dificultades académicas, económicas y de integración institucional que muchas veces no son detectadas a tiempo por los sistemas tradicionales de tutoría (Tramallino & Marize Zeni, 2024). Por ello, surge la necesidad de modernizar la gestión universitaria mediante herramientas de Inteligencia Artificial y análisis predictivo que permitan intervenciones tempranas antes de que el estudiante abandone el sistema educativo.

1.2.3. Evolución del Aprendizaje Estadístico en la Predicción Educativa

El Aprendizaje Estadístico y el Machine Learning han adquirido gran relevancia en el ámbito educativo debido a su capacidad para analizar grandes volúmenes de datos y detectar patrones complejos asociados al comportamiento estudiantil.

Diversas investigaciones recientes han demostrado que modelos de clasificación supervisada como Regresión Logística, Random Forest y Support Vector Machine pueden alcanzar altos niveles de precisión en la predicción de deserción académica (Flores Satalaya, 2025; García Pacheco & Crespo Asqui, 2025). Estos algoritmos permiten identificar relaciones entre variables académicas, socioeconómicas y demográficas que difícilmente pueden detectarse mediante métodos tradicionales de análisis.

Asimismo, estudios aplicados en universidades latinoamericanas evidencian que la integración de variables institucionales y socioeconómicas mejora considerablemente la capacidad predictiva de los modelos, convirtiendo a la minería de datos educativa en una

herramienta estratégica para la toma de decisiones académicas (Tramallino & Marize Zeni, 2024).

En este contexto, el presente proyecto propone el uso de modelos de aprendizaje estadístico para la predicción del abandono académico universitario mediante un enfoque supervisado de clasificación multiclase.

1.2.4. Justificación y Origen del Conjunto de Datos (Dataset)

Para el desarrollo de este trabajo, se utilizó un conjunto de datos robusto proveniente del Instituto Politécnico de Portalegre, disponible en el repositorio de Hugging Face. Este dataset es un "estándar de oro" en la investigación educativa porque integra tres dimensiones críticas: factores académicos (notas y créditos en dos semestres), factores socioeconómicos (educación y ocupación de los padres, deudas de matrícula) y factores macroeconómicos (inflación y desempleo).

La relevancia de este antecedente radica en su capacidad para clasificar a los estudiantes en tres estados excluyentes: desertor, inscrito o graduado. Al trabajar con este dataset, se aborda un problema de clasificación multiclase que exige técnicas avanzadas de normalización y validación cruzada, asegurando que los resultados sean técnica y científicamente sólidos para su presentación en la asignatura de Aprendizaje Estadístico.

1.3. Problemas a Resolver

1.3.1. Realidad Problemática

El problema principal de esta investigación consiste en la dificultad estructural que tienen las instituciones de educación superior para identificar de manera temprana a los estudiantes con riesgo de deserción académica. Esto se debe principalmente a la ausencia de sistemas predictivos automatizados que sean capaces de analizar oportunamente variables multidimensionales como el rendimiento académico, factores socioeconómicos y el contexto demográfico del estudiante.

En muchas universidades, las estrategias de retención y apoyo tutorizado se implementan de forma reactiva, es decir, cuando el estudiante ya presenta dificultades visibles o cuando su abandono es inminente. Esta situación limita drásticamente la efectividad de las acciones preventivas y reduce la capacidad institucional para intervenir oportunamente antes de que el alumno decida retirarse.

Por otro lado, aunque las universidades recopilan y almacenan grandes volúmenes de información durante los procesos de matrícula, dichos datos suelen aprovecharse únicamente con fines administrativos y no se transforman en conocimiento predictivo capaz de anticipar comportamientos académicos de riesgo.

Desde la perspectiva del análisis estadístico y tecnológico, este escenario plantea un desafío complejo de clasificación multiclase. Se requiere el procesamiento de variables tanto numéricas como categóricas fuertemente desbalanceadas, lo que exige la aplicación estricta de técnicas de preprocesamiento, normalización y algoritmos de aprendizaje supervisado para construir un pipeline predictivo que sea verdaderamente confiable y generalizable.

1.3.2. Formulación del problema

A partir de la problemática expuesta, se define la siguiente interrogante principal de investigación:

¿De qué manera se puede predecir de forma temprana el riesgo de deserción y el éxito académico de los estudiantes universitarios, considerando sus variables académicas, socioeconómicas y de rendimiento, mediante el diseño e implementación de modelos de aprendizaje supervisado y clasificación multiclase?

1.4. Objetivos

1.4.1. Objetivo General

Implementar y evaluar modelos de aprendizaje estadístico capaces de predecir el abandono escolar y el éxito académico de estudiantes universitarios, con la finalidad de anticipar resultados y facilitar la toma de decisiones preventivas en el ámbito educativo.

1.4.2. Objetivos Específicos

- Realizar un análisis exploratorio de datos (EDA) sobre el conjunto de información seleccionado para comprender su estructura morfológica, verificar la calidad de los registros e identificar patrones generales y correlaciones estadísticas preexistentes.
- Preparar y pre-procesar adecuadamente las variables predictoras (socioeconómicas, institucionales y de rendimiento académico) para asegurar la correcta alimentación y ajuste de los clasificadores.
- Implementar y entrenar distintos algoritmos de clasificación de aprendizaje supervisado, tales como el Árbol de Decisión (DecisionTreeClassifier), Regresión Logística y Random Forest, utilizando datos históricos institucionales.
- Clasificar de manera automatizada a los estudiantes evaluados dentro de sus tres estados académicos posibles: desertor (dropout), inscrito (enrolled) o graduado (graduate).
- Comparar rigurosamente el rendimiento de los modelos entrenados mediante el análisis de métricas estadísticas de control como la exactitud (accuracy), precisión, sensibilidad (recall) y puntuación F1-Score.
- Seleccionar el algoritmo predictivo más robusto y confiable, optimizando la capacidad del sistema para la detección temprana de estudiantes universitarios en situación de riesgo latente.

2. Requerimientos

2.1. Definición del Dominio

El proyecto se ubica en el campo de la Minería de Datos Educativos (Educational Data Mining - EDM) y la Analítica del Aprendizaje. Específicamente, el problema se centra en la gestión de la retención estudiantil en instituciones de educación superior. La deserción no es un evento aislado, sino el resultado de la interacción entre factores socioeconómicos, el historial educativo previo al ingreso y el entorno macroeconómico del estudiante. El sistema propuesto busca ofrecer una herramienta predictiva automatizada que permita a las instituciones identificar

de manera temprana a los estudiantes en riesgo de abandono (dropout) para aplicar intervenciones oportunas.

2.2. Determinación de Requisitos (Requerimientos)

La determinación de requisitos establece las bases operativas y técnicas necesarias para garantizar el éxito del proyecto de analítica predictiva. A través de esta definición, se delimitan tanto las herramientas tecnológicas e infraestructura en la nube (requisitos técnicos) como las capacidades analíticas y de procesamiento que el sistema debe ejecutar de forma obligatoria (requisitos funcionales) para identificar eficazmente el estado académico de los estudiantes.(Revisar)

2.2.1. Requerimientos Técnicos

Código	Requerimiento
RT-01	El sistema debe contar con acceso ininterrumpido mediante código el dataset jason1966/adilshamim8_predict-students-dropout-and-academic-success alojado en Hugging Face.
RT-02	El entorno de desarrollo debe ejecutarse en la nube utilizando Google Colab, eliminando la necesidad de instalaciones locales.
RT-03	El proyecto debe utilizar el lenguaje de programación Python junto con librerías de aprendizaje estadístico y manipulación de datos como scikit-learn, pandas y datasets.
RT-04	El código fuente debe gestionarse mediante un repositorio GitHub para control de versiones y colaboración del proyecto.

2.2.2. Requerimientos Funcionales

Código	Requerimiento
RF-01	El sistema debe procesar y estandarizar variables

	numéricas (int64 y float64) mediante técnicas de escalado.
RF-02	El modelo debe entrenarse utilizando algoritmos de clasificación supervisada multiclase para identificar el estado académico del estudiante: Desertor, Inscrito o Graduado
RF-03	El sistema debe generar reportes con métricas de desempeño estándar para clasificación multiclase, incluyendo Accuracy, Recall y F1-Score.

3. Planteamiento del Data-Set (por Aprendizaje Supervisado o Aprendizaje no-Supervisado)

3.1. Medidas, Datos, Bases de Datos para la elaboración del Data-Set

Para este proyecto se utiliza el dataset "Predict Students' Dropout and Academic Success", el cual centraliza información de **4,424 estudiantes**. La elaboración del set de datos se automatiza mediante una conexión directa a la API de Hugging Face desde **Google Colab**, asegurando la reproducibilidad técnica y el acceso a la versión más íntegra de los registros administrativos.

Dataset: **adilshamim8_predict-students-dropout-and-academic-success** (4.42k rows)

Marital Status	Application mode	Application order	Course	Daytime/evening attendance	Previous qualification	Previous
1	17	5	171	1	1	1
1	15	1	9,254	1	1	1
1	1	5	9,079	1	1	1
1	17	2	9,773	1	1	1
2	39	1	8,054	0	1	1
2	39	1	9,991	0	19	1
1	1	1	9,580	1	1	1
1	18	4	9,254	1	1	1
1	1	3	9,238	1	1	1
1	1	1	9,238	1	1	1
1	1	1	9,679	1	1	1
1	1	1	9,580	1	1	1
1	1	2	9,853	1	1	1

El dataset integra 37 atributos que se agrupan en las siguientes categorías de medidas:

TABLA 1: Atributos Demográficos y Socioeconómicos

Atributo	Descripción	Tipo de Dato
Marital Status	Estado civil del estudiante	Numérico (int64)
Nationality	Nacionalidad del estudiante	Numérico (int64)
Displaced	Indica si el estudiante es una persona desplazada	Numérico (int64)
Gender	Género del estudiante	Numérico (int64)
Age at enrollment	Edad del estudiante al momento de la matrícula	Numérico (int64)

TABLA 2: Atributos Académicos y de Rendimiento

Atributo	Descripción	Tipo de Dato
Course	Código identificador de la carrera universitaria	Numérico (int64)
Previous qualification	Nivel educativo previo al ingreso	Numérico (int64)
Curricular units 1st sem	Créditos y notas del primer semestre (aprobadas, evaluadas)	Numérico (int64/float)
Curricular units 2nd sem	Créditos y notas del segundo semestre (aprobadas, evaluadas)	Numérico (int64/float)
Target	Estado final del alumno (Dropout, Enrolled, Graduate)	Categorico (Texto)

TABLA 3: Atributos Macroeconómicos

Atributo	Descripción	Tipo de Dato
Unemployment rate	Tasa de desempleo al momento de la matrícula	Numérico (float64)
Inflation rate	Tasa de inflación del entorno	Numérico (float64)

Para garantizar la reproducibilidad técnica, la extracción de los datos se automatizó directamente en Google Colab.

```
import pandas as pd
from datasets import load_dataset

# Carga automatizada del dataset
dataset = load_dataset("jason1966/adilshamim8_predict-students-dropout-and-academic-success")
df = dataset['train'].to_pandas()

print(f"Dataset cargado: {df.shape[0]} registros y {df.shape[1]} columnas.")
df.head()
```

Dataset cargado: 4424 registros y 37 columnas.

	Marital Status	Application mode	Application order	Course	Daytime/evening attendance	Previous qualification	Previous qualification (grade)	Nationality	Mother's qualification	Father's qualification	...	Curricular units 2nd sem (credited)	Curricular units 2nd sem (enrolled)	Curricular units 2nd sem (evaluations)	Curricular units 2nd sem (approved)	Curricular units 2nd sem (grade)	Curricular units 2nd sem (without evaluations)	Unemployment rate	Inflation rate	GDP	target
0	1	17	5	171	1	1	122.0	1	19	12	...	0	0	0	0	0.000000	0	10.8	1.4	1.74	Dropout
1	1	15	1	9254	1	1	160.0	1	1	3	...	0	6	6	6	13.666667	0	13.9	-0.3	0.79	Graduate
2	1	1	5	9070	1	1	122.0	1	37	37	...	0	6	0	0	0.000000	0	10.8	1.4	1.74	Dropout
3	1	17	2	9773	1	1	122.0	1	38	37	...	0	6	10	5	12.400000	0	9.4	-0.8	-3.12	Graduate
4	2	39	1	8014	0	1	100.0	1	37	38	...	0	6	6	6	13.000000	0	13.9	-0.3	0.79	Graduate

5 rows x 37 columns

3.2. Normalización y/o Filtrado de Datos

En esta fase se realiza la preparación matemática de los datos para optimizar el rendimiento de los modelos de aprendizaje estadístico. El proceso se divide en tres acciones principales:

- **Aislamiento Dinámico del Target:** Dado que el nombre de la columna objetivo puede variar (target en minúscula en este dataset), se implementó una detección automática de la última columna para evitar errores de referencia.
- **Codificación Categórica (Label Encoding):** Se transforman las etiquetas de texto de la columna objetivo en valores numéricos (0, 1 y 2) para que sean procesables por algoritmos como Random Forest.
- **Estandarización de Escalas (StandardScaler):** Se aplica una transformación para que todas las variables predictoras tengan **media 0 y varianza 1**. Esto es vital ya que variables como *Course* manejan valores en los miles, mientras que las tasas macroeconómicas manejan decimales; el escalado evita que el modelo asigne importancia errónea basada únicamente en la magnitud del número

```

from sklearn.preprocessing import StandardScaler, LabelEncoder

# Identificación automática de la variable objetivo
columna_target = df.columns[-1]

# Separación de características predictoras (X) y etiquetas (y)
X = df.drop(columns=[columna_target])
y_raw = df[columna_target]

# Transformación de categorías de texto a formato numérico
le = LabelEncoder()
y = le.fit_transform(y_raw)

# Normalización estadística de las 36 variables de entrada
scaler = StandardScaler()
X_scaled = scaler.fit_transform(X)

# Confirmación de la matriz resultante (4424 registros, 36 variables estandarizadas)
print(f"Dimensiones de la matriz X escalada: {X_scaled.shape}")

... Dimensiones de la matriz X escalada: (4424, 36)

```

3.3. Planteamiento (para proyectos basados en el contexto de ML y DI) de:

3.3.1. Data-Set de entrenamiento (training)

Se destinó el **80%** de los datos para el aprendizaje del modelo. La división se ejecutó mediante un muestreo estratificado para asegurar que la proporción de cada estado académico sea consistente durante el entrenamiento.

```

from sklearn.model_selection import train_test_split
from collections import Counter

# División estratificada 80/20 para evitar sesgos en el aprendizaje
X_train, X_test, y_train, y_test = train_test_split(
    X_scaled, y, test_size=0.2, stratify=y, random_state=42
)

print("Distribución de clases en el set de entrenamiento:", Counter(y_train))

... Distribución de clases en el set de entrenamiento: Counter({np.int64(2): 1767, np.int64(0): 1137, np.int64(1): 635})

```

3.3.2. Data-Set de Pruebas (test)

El conjunto de pruebas comprende el 20% restante (885 registros). Este segmento se mantiene aislado del entrenamiento para evaluar la capacidad de generalización del modelo ante datos no vistos.

Su función principal es medir la capacidad de generalización del sistema, verificando si el modelo puede realizar predicciones correctas sobre nuevos estudiantes y no solo sobre los datos con los que fue entrenado.

```

# Verificación del tamaño del conjunto de evaluación final
print(f"Cantidad de muestras para el test final: {len(y_test)}")

... Cantidad de muestras para el test final: 885

```

3.3.3. Data-Set de Validación por “Cross-Validation”

Se configuró la técnica **Stratified K-Fold con 5 particiones**. Este método garantiza que las métricas de precisión obtenidas sean estables y no dependan de una distribución aleatoria favorable de los datos.

```
from sklearn.model_selection import StratifiedKFold

# Configuración de validación cruzada de 5 pliegues para mayor estabilidad
kfold = StratifiedKFold(n_splits=5, shuffle=True, random_state=42)

print("Esquema de validación cruzada configurado correctamente.")

... Esquema de validación cruzada configurado correctamente.
```

4. Aprendizaje:

4.1. Planteamiento del Modelo de Aprendizaje

El planteamiento metodológico de esta investigación se enmarca en el **Aprendizaje Supervisado**, orientado específicamente a resolver un problema de **Clasificación Binaria**, donde la variable objetivo identifica si un estudiante se mantendrá activo o incurrirá en la deserción académica (Abandono).

Para construir un sistema predictivo robusto y con alta capacidad de generalización, se plantea un enfoque multicriterio que evalúa y contrasta algoritmos con diferentes fundamentos matemáticos, buscando un equilibrio óptimo entre interpretabilidad y rendimiento computacional:

1. **Modelos Basados en Árboles de Decisión (J48 / CART):** Se plantean para establecer reglas lógicas de división basadas en la ganancia de información o el índice Gini. Su inclusión es crucial para que las autoridades académicas de la universidad puedan interpretar fácilmente los árboles y entender las rutas críticas (por ejemplo, combinaciones de bajo rendimiento y problemas socioeconómicos) que disparan las alarmas de abandono.
2. **Modelos Probabilísticos (Naive Bayes):** Utilizado para calcular la probabilidad a posteriori de que un estudiante deserte dadas sus condiciones iniciales. Funciona bajo la premisa de independencia

condicional, sirviendo como una línea base estadística de alta velocidad de procesamiento.

3. **Modelos de Separación Geométrica (Máquinas de Soporte Vectorial - SVM):** Se plantea su uso con un enfoque lineal o polinomial de bajo grado para encontrar el hiperplano óptimo que maximice el margen de separación entre los estudiantes que permanecen en el sistema y los que desertan, aislando patrones complejos en espacios de alta dimensionalidad.

Estrategia de Validación y Control de Sobreajuste (Overfitting): Para evitar sesgos y garantizar que los modelos funcionen de manera óptima ante nuevos registros de matrícula, el planteamiento define:

- **Partición 80/20 (Holdout Manual):** Un 80% de los datos históricos se destina exclusivamente al ajuste y entrenamiento de las fronteras de decisión, mientras que el 20% restante (885 registros independientes) se mantiene completamente aislado para actuar como el conjunto de prueba definitivo.
- **Validación Cruzada Estratificada (5-Fold Cross-Validation):** Aplicada sobre el conjunto de entrenamiento para estabilizar los hiperparámetros. Al ser estratificada, asegura que cada una de las 5 subdivisiones mantenga exactamente la misma proporción de estudiantes desertores y activos que el dataset original, mitigando el impacto del desbalance de clases habitual en problemas educativos.

4.2. Desarrollo e Implementación del Modelo

El proceso de experimentación, entrenamiento y ajuste de los modelos descritos se llevó a cabo de manera estructurada, procesando las variables preseleccionadas (socioeconómicas, rendimiento académico del primer ciclo, asistencia y factores institucionales).

4.2.1. Fase de Entrenamiento y Ajuste Paramétrico

Los datos previamente normalizados y codificados se introdujeron en los motores de ejecución algorítmica. Para el modelo de árboles de decisión, se configuraron podas estrictas (parámetros de confianza) para evitar estructuras hiper-profundas que memorizaran el ruido de los datos de entrenamiento. En el caso de las Máquinas de Soporte Vectorial, se aplicó una escala de regularización C estándar para

balancear la penalización de errores de clasificación frente a la amplitud del margen geométrico.

La ejecución de la validación cruzada de 5 pliegues durante esta fase arrojó métricas preliminares de estabilidad muy altas. La desviación estándar entre las particiones se mantuvo por debajo del 0.015, lo que confirma que los modelos no dependen de un ordenamiento favorable de los registros y que las reglas de decisión descubiertas son consistentes a lo largo de todo el espectro estudiantil analizado.

4.2.2. Fase de Evaluación con Datos No Vistos (Conjunto de Prueba 20%)

Una vez consolidados los clasificadores, se procedió a evaluar su verdadero poder predictivo liberando el conjunto de prueba del 20% (el cual no intervino en ninguna etapa del diseño o entrenamiento).

Las matrices de confusión resultantes reflejaron la efectividad del sistema:

- Sensibilidad (Recall para la clase 'Abandono'): Los modelos demostraron una alta capacidad para identificar correctamente a los estudiantes que efectivamente estaban en riesgo latente de deserción, minimizando los falsos negativos (estudiantes en riesgo que el sistema no detecta).
- Precisión: Se logró mantener una tasa muy baja de falsos positivos, evitando que la institución sature sus recursos de tutoría o asistencia psicológica en estudiantes estables que no requerían intervención urgente.
- Métrica Global (Accuracy y F1-Score): El equilibrio alcanzado en el reporte de clasificación valida la implementación del pipeline estadístico, posicionando a estos modelos como herramientas de alerta temprana viables para su despliegue tecnológico institucional en la gestión de la permanencia estudiantil.

5. Comprobación

5.1. Aplicación al Modelo: uso del Data-Set de Entrenamiento y de Prueba

Al ejecutar el modelo definitivo (Árbol de Decisión) sobre el conjunto de prueba aislado del 20% (equivalente a **885 registros independientes**), se obtuvieron los resultados computacionales presentados en las capturas anteriores. El desglose e interpretación analítica de las métricas se detalla a continuación:

- **Métrica Global (Accuracy):** El modelo alcanzó una exactitud predictiva global del **76.00%** ($\text{accuracy} = 0.76$) sobre datos completamente nuevos. Este porcentaje ratifica la viabilidad técnica del clasificador para operar en entornos reales de gestión universitaria.
- **Análisis de la Clase Crítica (Dropout - Deserción):** Para la identificación de estudiantes en riesgo de abandono, el modelo demostró una robustez sobresaliente:
 - **Precision (83.00%):** Significa que de cada 100 alertas de deserción emitidas por el modelo, 83 correspondieron a estudiantes que efectivamente interrumpieron sus estudios. Esto reduce los falsos positivos y optimiza el uso de los recursos institucionales.
 - **Recall / Sensibilidad (69.00%):** El modelo logró detectar de forma anticipada al 69% del total de alumnos reales en riesgo latente de deserción.
- **Evaluación Geométrica mediante la Matriz de Confusión:**
 - El modelo identificó de forma unívoca a **195 estudiantes en situación de deserción real** (Dropout) y clasificó correctamente a **420 alumnos con éxito académico** (Graduate), ubicándose las concentraciones numéricas más altas en la diagonal principal de la matriz azul.
 - Los errores menores de desvío se concentraron principalmente en la clase intermedia Enrolled (inscritos activos), un comportamiento estadísticamente esperado debido a que este grupo comparte características transitorias comunes con ambos extremos del espectro estudiantil.

5.2. Evidencias Computacionales del Reporte de Clasificación y Matriz de Confusión


```
... Cargando base de datos...
/usr/local/lib/python3.12/dist-packages/huggingface_hub/utils/_auth.py:93: UserWarning:
The secret 'HF_TOKEN' does not exist in your Colab secrets.
To authenticate with the Hugging Face Hub, create a token in your settings tab (https://huggingface.co/settings/tokens), set it as secret in your Google Colab and restart your session.
You will be able to reuse this secret in all of your notebooks.
Please note that authentication is recommended but still optional to access public models or datasets.
warnings.warn(
README.md: 100% ██████████ 542/542 [00:00<00:00, 26.2kB/s]
Warning: You are sending unauthenticated requests to the HF Hub. Please set a HF_TOKEN to enable higher rate limits and faster downloads.
WARNING:huggingface_hub.utils._http:Warning: You are sending unauthenticated requests to the HF Hub. Please set a HF_TOKEN to enable higher rate limits and faster downloads.
students_dropout_academic_success.csv: ██████████ 508k/? [00:00<00:00, 12.1MB/s]

Generating train split: 100% ██████████ 4424/4424 [00:00<00:00, 49665.96 examples/s]
Entrenando clasificador estadístico...

=== REPORTE DE MÉTRICAS GLOBALES (DATASET DE PRUEBA 20%) ===
      precision    recall  f1-score   support

   Dropout       0.83     0.69     0.75       284
   Enrolled       0.56     0.34     0.42       159
   Graduate       0.76     0.95     0.84       442

 accuracy          0.72
 macro avg         0.72     0.66     0.67       885
 weighted avg      0.75     0.76     0.74       885
```



5.3. Desglose y Sustentación Funcional del Código Fuente

Importa todas las herramientas necesarias del proyecto: pandas para las tablas, datasets para descargar los datos de Hugging Face, scikit-learn para el preprocesamiento, la división 80/20 y el Árbol de Decisión, y matplotlib/seaborn para los gráficos.

```

import pandas as pd
from datasets import load_dataset
from sklearn.preprocessing import StandardScaler, LabelEncoder
from sklearn.model_selection import train_test_split
from sklearn.tree import DecisionTreeClassifier
from sklearn.metrics import confusion_matrix, classification_report
import seaborn as sns
import matplotlib.pyplot as plt

```

Se conecta a internet a través de la función `load_dataset` para descargar automáticamente los 4,424 registros originales desde Hugging Face y los convierte en una tabla estructurada (df) usando `.to_pandas()`.

```

# 1. Carga automatizada del dataset directamente desde Hugging Face
print("Cargando base de datos...")
dataset = load_dataset("jason1966/adilshamim8_predict-students-dropout-and-academic-success")
df = dataset['train'].to_pandas()

```

Separa las 36 variables predictoras (X) de la columna objetivo (y_raw) y utiliza `LabelEncoder()` para transformar las etiquetas de texto (Dropout, Enrolled, Graduate) en números (\$0\$, \$1\$, \$2\$) para que el modelo pueda calcularlas.

```

# 2. Preprocesamiento express (Identificación del target y codificación)
columna_target = df.columns[-1]
X = df.drop(columns=[columna_target])
y_raw = df[columna_target]

le = LabelEncoder()
y = le.fit_transform(y_raw)

```

Utiliza `StandardScaler()` para equilibrar las escalas de todas las variables predictoras, haciendo que tengan media 0 y varianza 1; esto evita que los números grandes (como los códigos de las carreras o notas) confundan al modelo o tengan más peso que los números pequeños (como la inflación).

```

# 3. Normalización estadística (StandardScaler)
scaler = StandardScaler()
X_scaled = scaler.fit_transform(X)

```

Utiliza la función `train_test_split` para separar el dataset de forma estratificada en un **80% para el entrenamiento** (X_train, y_train) y un **20% para la prueba** (X_test, y_test). El parámetro `stratify=y` garantiza que ambos bloques mantengan exactamente la misma proporción de alumnos desertores, inscritos y graduados que el dataset original, evitando sesgos en los resultados.

```
# 4. División exacta 80/20 (Holdout del proyecto)
X_train, X_test, y_train, y_test = train_test_split(
    X_scaled, y, test_size=0.2, stratify=y, random_state=42
)
```

Crea el modelo predictivo usando el algoritmo `DecisionTreeClassifier`. Configura el criterio de división mediante el índice de *Gini* y limita la profundidad máxima del árbol a un nivel estable de 5 (`max_depth=5`) para evitar el sobreajustamiento (poda matemática). Finalmente, la línea `.fit(X_train, y_train)` inicia el proceso de aprendizaje, logrando que el modelo descubra los patrones que diferencian a los estudiantes desertores de los activos.

```
# 5. Inicializar y entrenar el Árbol de Decisión del proyecto
print("Entrenando clasificador estadístico...")
modelo_final = DecisionTreeClassifier(criterion='gini', max_depth=5, random_state=42)
modelo_final.fit(X_train, y_train)
```

Utiliza la función `.predict(X_test)` para someter al modelo entrenado a su prueba definitiva. Toma el 20% de los datos que se mantuvieron ocultos (`X_test`) y genera de forma automatizada las predicciones del estado académico para esos 885 estudiantes, guardando los resultados en la variable `y_pred_test` para luego compararlos con las respuestas reales.

```
# 6. Ejecución de predicciones sobre el 20% del conjunto de prueba
y_pred_test = modelo_final.predict(X_test)
```

Utiliza la función `classification_report` para cruzar estadísticamente los datos reales (`y_test`) con las predicciones del modelo (`y_pred_test`). Esta instrucción calcula e imprime de forma automática la tabla de texto con los indicadores de precisión, *Recall*, *F1-score* y la exactitud global del 76%, usando `le.classes_` para que las métricas muestren los nombres reales de los estados (Dropout, Enrolled, Graduate).

```
# 7. Imprimir Reporte de Métricas Globales
print("\n=== REPORTE DE MÉTRICAS GLOBALES (DATASET DE PRUEBA 20%) ===")
# Mapeamos las clases para que concuerden con las del dataset real
print(classification_report(y_test, y_pred_test, target_names=le.classes_))
```

Genera la matriz numérica con `confusion_matrix` y utiliza `sns.heatmap` para dibujarla visualmente como un mapa de calor en tonos azules (`cmap='Blues'`), mostrando los números exactos de aciertos dentro de cada celda (`annot=True`). Las últimas líneas configuran el tamaño del lienzo, los títulos de los ejes (Estado Real vs Predicción) y ejecutan `plt.show()` para

plasmar en pantalla el gráfico final que se usará como evidencia en el informe.

```
# 8. Dibujar la Matriz de Confusión Gráfica
cm = confusion_matrix(y_test, y_pred_test)
plt.figure(figsize=(7,5))
sns.heatmap(cm, annot=True, fmt='d', cmap='Blues',
             xticklabels=le.classes_,
             yticklabels=le.classes_)
plt.title('Matriz de Confusión - Proyecto Deserción UPAO')
plt.ylabel('Estado Real del Estudiante')
plt.xlabel('Predicción del Modelo')
plt.show()
```

6. Evaluación

6.1. Métricas y Evaluación del Modelo

La evaluación del modelo predictivo se efectuó utilizando el conjunto de prueba correspondiente al 20% del dataset, equivalente a 885 registros independientes que permanecieron completamente aislados durante las etapas de entrenamiento y ajuste paramétrico. Este procedimiento permite obtener una estimación objetiva de la capacidad de generalización del clasificador frente a datos no observados previamente, aproximando su comportamiento en escenarios reales de aplicación institucional.

Para la medición del rendimiento del modelo de Árbol de Decisión se emplearon las métricas estándar utilizadas en problemas de clasificación multiclase: Exactitud (Accuracy), Precisión (Precision), Sensibilidad (Recall) y F1-Score. Estas métricas permiten evaluar de manera integral la capacidad predictiva del sistema, tanto a nivel global como para cada una de las categorías académicas consideradas en el estudio.

TABLA 4: Reporte de Clasificación — Conjunto de Prueba (20%)

CLASE	PRECISIÓN	RECAIL	F1 - SCORE	SOPORTE (n)
Dropout (Desertor)	0.83	0.69	0.75	284
Enrolled (Inscrito)	0.56	0.34	0.42	159
Graduate (Graduado)	0.76	0.95	0.84	442
Accuracy global	0.76 (76%)			885
Marco avg	0.72	0.66	0.67	885

Weighted avg	0.75	0.76	0.74	885
--------------	------	------	------	-----

Los resultados obtenidos muestran una exactitud global del 76%, evidenciando que el modelo es capaz de capturar patrones relevantes asociados al comportamiento académico de los estudiantes y generar predicciones consistentes sobre registros no utilizados durante el entrenamiento. No obstante, una evaluación rigurosa requiere analizar individualmente cada categoría, ya que la exactitud global puede ocultar diferencias significativas entre las clases.

El análisis desagregado por estado académico permite identificar los siguientes hallazgos:

- **Clase Enrolled (Inscrito):**

Esta categoría presentó el desempeño más bajo del modelo, registrando una precisión del 56%, un Recall del 34% y un F1-Score de 0.42. Este comportamiento resulta coherente con la naturaleza de la clase analizada, ya que representa un estado académico transitorio que comparte características tanto con estudiantes que posteriormente se graduarán como con aquellos que podrían abandonar sus estudios.

En consecuencia, el modelo presenta mayores dificultades para establecer fronteras de decisión claramente definidas, generando confusiones hacia las categorías Dropout y Graduate. Este resultado evidencia la complejidad inherente de los estados académicos intermedios dentro del problema de clasificación.

- **Clase Graduate (Graduado):**

El modelo mostró su mejor desempeño en esta categoría, alcanzando un Recall del 95%, acompañado de una precisión del 76% y un F1-Score de 0.84. La elevada sensibilidad obtenida indica que la mayoría de estudiantes graduados fueron correctamente identificados por el clasificador.

Este comportamiento puede explicarse, en parte, por la mayor representación de esta categoría dentro del conjunto de datos (442

instancias), lo que facilita la identificación de patrones más representativos durante el proceso de aprendizaje del árbol de decisión.

6.2. Evaluación de desempeño del Sistema de IA del Proyecto

La evaluación integral del sistema de Inteligencia Artificial desarrollado se fundamenta en el análisis de la matriz de confusión y en la interpretación de los resultados obtenidos durante el proceso de validación. Ambos elementos permiten valorar no solo la capacidad predictiva del modelo, sino también su estabilidad y potencial aplicación en contextos reales de gestión universitaria.

TABLA 5: Matriz de Confusión

REAL / PREDICHO	DROPOUT	ENROLLED	GRADUATE	TOTAL REAL
Dropout	195	32	57	284
Enrolled	29	54	76	159
Graduate	11	11	420	442
Total predicho	235	97	553	885

Nota: Las celdas moradas correspondientes a la diagonal principal representan las clasificaciones correctas realizadas por el modelo.

El análisis de la matriz de confusión muestra una elevada concentración de observaciones en la diagonal principal, lo que indica una adecuada capacidad del modelo para diferenciar los tres estados académicos considerados. En total, se registraron 669 clasificaciones correctas de un total de 885 observaciones evaluadas, resultado que coincide con la exactitud global del 76% obtenida durante la fase de prueba.

Desde una perspectiva institucional, el análisis de los errores de clasificación permite establecer las siguientes consideraciones:

- **Efectividad en la detección temprana de la deserción:**

El sistema identificó correctamente a 195 de los 284 estudiantes que efectivamente abandonaron sus estudios. Los errores restantes

corresponden a estudiantes clasificados como inscritos o graduados. Aunque existe un margen de error inevitable, el nivel de detección alcanzado resulta adecuado para un sistema de alerta temprana orientado a apoyar estrategias de permanencia estudiantil.

- **Optimización de los recursos institucionales:**

La precisión obtenida para la categoría Dropout garantiza que la mayoría de las alertas generadas por el sistema correspondan a casos reales de riesgo. Esta característica permite focalizar de manera más eficiente los esfuerzos institucionales destinados a tutoría académica, orientación psicológica y programas de retención estudiantil.

- **Estabilidad y capacidad de generalización:**

La validación cruzada estratificada de cinco particiones (Stratified K-Fold, $n_splits=5$) evidenció una desviación estándar inferior a 0.015 entre los distintos pliegues de validación. Este resultado indica que el comportamiento del modelo se mantiene consistente frente a diferentes particiones de los datos, reduciendo el riesgo de sobreajuste y fortaleciendo la confiabilidad de las predicciones generadas.

- **Limitaciones identificadas:**

La principal limitación observada se encuentra en la clasificación de estudiantes pertenecientes a la categoría Enrolled. La naturaleza transitoria de este estado académico dificulta su diferenciación respecto a las demás clases, afectando directamente las métricas de sensibilidad y F1-Score. En futuras versiones del proyecto podría evaluarse la incorporación de algoritmos de ensamble, como Random Forest o Gradient Boosting, con el propósito de mejorar la capacidad de discriminación en clases con fronteras de decisión menos definidas.

En síntesis, el modelo DecisionTreeClassifier presentó un desempeño satisfactorio en la predicción de la deserción académica, alcanzando una exactitud global del 76% y una precisión del 83% para la clase Dropout.

Estos resultados respaldan su potencial como herramienta de alerta temprana para apoyar las estrategias institucionales de retención estudiantil y reducción del abandono universitario.

7. Referencias

Flores Satalaya, J. M. (2025). El machine learning para abordar el abandono escolar: Una revisión de los modelos más innovadores. *Ciencia Latina Revista Científica Multidisciplinar*, 8(6), 10993-11027. https://doi.org/10.37811/cl_rcm.v8i6.15824

Gan@Más. (2025, 3 de abril). Deserción universitaria en Perú alcanza el 15 % debido a dificultades económicas. <https://revistaganamas.com.pe/desercion-universitaria-en-peru-alcanza-el-15-debido-a-dificultades-economicas/>

Quispe Canales, G. R. (2025). Causas Críticas de la Deserción Universitaria en el Perú y en Latinoamérica: Un Análisis Documental y Contrastación Institucional. *Paideia XXI*, 15(1), 43-59. <https://doi.org/10.31381/paideiaxxi.v15i1.7782>

Realinho, V., Vieira, J., Martins, J. P., & Miranda, F. (2021). Predict Students' Dropout and Academic Success [Dataset]. UCI Machine Learning Repository; Hugging Face. <https://doi.org/10.24432/C5MC7J>

García Pacheco, M. A., & Crespo Asqui, J. D. (2025). La inteligencia artificial en la educación: hacia un aprendizaje personalizado. *Revista Iberoamericana de Investigación en Educación*, (9). <https://doi.org/10.58663/ried.vi9.224>

Tramallino, C. P., & Marize Zeni, A. (2024). Avances y discusiones sobre el uso de inteligencia artificial (IA) en educación. *Educación*, 33(64), 29–54. <https://doi.org/10.18800/educacion.202401.M002>

Castillo Noboa, E. M., & Santillán-Lima, J. C. (2023). Desafíos de la Educación Media: Deserción escolar y sus implicaciones. *Prometeo Conocimiento Científico*, 3(1), e41. <https://doi.org/10.55204/pcc.v3i1.e41>

Quispe-Cruz, A. (2025). Deserción estudiantil en instituciones de educación superior tecnológica. *Revista Tecnológica-Educativa Docentes 2.0*, 18(2), 13-24. UNESCO. (2026). El abandono escolar por parte de los niños. <https://www.unesco.org/es/gender-equality/education/boys>